LAPORAN DATA PREPARATION

Ringkasan pembahasan dan kondisi dataset

Laporan ini merangkum fungsi simulation/data_prep.py, penyesuaian pembacaan file sumber, dan isi tiga file hasil persiapan data yang diperiksa.

1. Tujuan data preparation

Skrip memuat data pelanggan, pesanan, ringkasan produk, dan pendapatan bulanan. Setelah memeriksa kolom wajib, skrip membentuk fitur pelanggan, membagi dataset secara stratified menjadi data latih dan data uji, lalu menyimpan CSV serta laporan kualitas data.

2. Penyesuaian pada skrip

customers.csv menggunakan pemisah titik koma, sementara file sumber lain menggunakan koma. Pembacaan CSV disesuaikan agar pandas mendeteksi pemisah. Parsing registration_date juga disetel untuk format hari/bulan/tahun (dd/mm/yyyy).
Ketiga file hasil yang diperiksa sudah ada sebelum penyesuaian ini. Pemeriksaan eksekusi ulang belum selesai karena lingkungan Python tidak memiliki paket scikit-learn (sklearn), yang dibutuhkan saat mengimpor skrip.

3. Struktur dataset hasil

customer_ml_dataset.csv | 8.000 baris x 23 kolom
customer_train.csv | 6.400 baris x 23 kolom
customer_test.csv | 1.600 baris x 23 kolom
Data latih dan uji berjumlah 80% dan 20% dari dataset lengkap. Pembagian menggunakan stratifikasi berdasarkan churned agar proporsi kelas target terjaga.

4. Kolom-kolom

ID: customer_id. Kategori (7): country, gender, membership_tier, preferred_category, preferred_device, preferred_payment_method, acquisition_channel.
Numerik asli (10): age, total_orders, total_spend_usd, avg_order_value_usd, days_since_last_purchase, reviews_given, avg_review_score, returns_made, wishlist_items, newsletter_subscribed.
Fitur turunan (4): customer_tenure_days, orders_per_year, reviews_per_order, returns_per_order. Target: churned (0 atau 1).

5. Distribusi target saat file diperiksa

Dataset lengkap: churn 0 = 7.285; churn 1 = 715
Data latih: churn 0 = 5.828; churn 1 = 572
Data uji: churn 0 = 1.457; churn 1 = 143
Contoh baris pertama dataset lengkap: customer_id C00001, United States, Male, Free, usia 40, 4 pesanan, masa pelanggan 2.631 hari, churned 0.

6. Cara menjalankan ulang

Dari folder simulation, pasang dependensi dengan pip install -r requirements.txt, kemudian jalankan python data_prep.py. Skrip akan membuat ulang customer_ml_dataset.csv, customer_train.csv, customer_test.csv, dan data_quality_report.json.
Catatan: customers2.csv dan orders2.csv juga ada di folder, tetapi skrip saat ini membaca customers.csv dan orders.csv. Nilai pada file hasil yang dirangkum di atas adalah kondisi saat diperiksa; jalankan ulang setelah dependensi tersedia untuk memperbarui hasil dari sumber yang sekarang.